

Слайд 1: Титульний слайд

- **Текст:** "Доброго дня, шановні присутні! Мене звати Тунік Вадим, і сьогодні я представляю вашій увазі: "МоА+: Суміш автокодувальників зі змінними концентраціями для покращення кластеризації зображень"."

Слайд 2: МоА+: Ключові концепції та мотивація

- **Текст:** "У цій роботі представлено МоА+ – це нова модель, яка розшифровується як "Суміш автокодувальників зі змінними концентраціями". Її головна мета – забезпечити стабільну та якісну кластеризацію зображень за допомогою так званого "роутера". Основна проблема, яка вирішується в цій роботі, полягає в тому, що стандартні моделі "Суміші експертів" (або МоЕ) часто страждають від так званого "домінування експерта", коли один з "експертів" перетягує на себе всю роботу, що призводить до незбалансованого навчання. Моє рішення – це поєднання архітектури МоЕ з ідеями з "Моделей сумішей зі змінними концентраціями" (MVC) та додавання нової функції втрат для регуляризації."

Слайд 3: Вступ до Суміші Експертів (МоЕ) Хінтона

- **Текст:** "Щоб зрозуміти наведену модель, коротко розглянемо, що таке "Суміш експертів" або МоЕ. Це підхід у машинному навчанні, де ми не використовуємо одну велику модель, а комбінуємо декілька менших, спеціалізованих моделей, які називаються "експертами". Кожен експерт навчається розв'язувати свою частину задачі. А спеціальна "розподільна мережа" або "роутер" вирішує, якому експерту довірити обробку конкретних вхідних даних."

Слайд 4: Стандартна Суміш Експертів та її недоліки

- **Текст:** "У стандартному підході МоЕ для кластеризації зображень, "експертами" є автокодувальники, які намагаються відтворити вхідні зображення, а "роутер" визначає, наскільки кожен експерт підходить для конкретного зображення. Однак, тут виникає серйозна проблема – "домінування експерта". Це означає, що один експерт може стати "улюбленцем" роутера і отримувати більшість даних для обробки. В результаті цей експерт перенавчається, а інші залишаються недонавченими. Це призводить до неефективної кластеризації та низьких показників якості, таких як нормалізована взаємна інформація (NMI)."

Слайд 5: Вступ до Моделі Сумішей зі Змінними Концентраціями (MVC)

- **Текст:** "Тепер перейдемо до іншої важливої концепції – "Моделі сумішей зі змінними концентраціями" (MVC). Уявіть, що дані складаються з декількох груп, і кожна група має свій розподіл. У класичних моделях частка кожної групи вважається фіксованою. А в MVC ця частка, або "концентрація", може змінюватися для кожного окремого об'єкта даних. Для оцінки параметрів у таких моделях використовуються спеціальні "мінімаксні ваги", які допомагають збалансувати внесок кожного об'єкта."

Слайд 6: Синтез МоЕ та MVC у моделі МоА+

- **Текст:** "Модель МоА+ об'єднує найкраще з двох світів: архітектуру "Суміші експертів" та ідеї "Моделей сумішей зі змінними концентраціями". Реалізовано це шляхом модифікації функції втрат. Замість того, щоб просто використовувати ймовірності від роутера, обчислюються так звані "мінімаксні ваги", які допомагають регулювати роботу роутера. Головна мета – збалансувати роботу експертів, уникнути їх домінування та, як результат, покращити якість кластеризації зображень. Модифікована функція втрат враховує **індивідуальну** помилку реконструкції кожного експерта, зважену цими мінімаксними вагами."

Слайд 7: Експерти та Роутер в МоА+

- **Текст:** "В моделі МоА+ "експертами" є згорткові автокодувальники. Їхнє завдання – взяти вхідне зображення, стиснути його до компактного представлення, а потім відновити назад. Чим краще відновлення, тим краще експерт "зрозумів" даний тип зображень. "Роутер" – це також згорткова нейронна мережа. Він аналізує вхідне зображення і видає набір ймовірностей, які показують, який з експертів, на його думку, найкраще впорається з реконструкцією цього конкретного зображення. Тобто, роутер "направляє" зображення до найбільш підходящого експерта."

Слайд 8: Модифікована Функція Втрат

- **Текст:** "Ключова відмінність МоА+ полягає у функції втрат. У стандартному підході втрати розраховуються на основі зваженої суми реконструкцій усіх експертів. В цій роботі ж пропонується інший підхід: використовувати "мінімаксні ваги", які обчислюються на основі ймовірностей, виданих роутером. Ці ваги допомагають зважити індивідуальну помилку реконструкції кожного експерта. Прямая оптимізація такої функції втрат є складною через необхідність обернення матриці. Тому для оптимізації, особливо у випадку двох експертів, ми використовуємо її верхню оцінку, яка спрощує обчислення

градієнтів."

Слайд 9: Експерименти: Установки та Метрики

- **Текст:** "Для перевірки ефективності моделі MoA+ було проведено низку експериментів, порівнюючи її з класичною моделлю "Суміші експертів" Хінтона. Архітектурно моделі схожі, головна відмінність – у функції втрат. Ми використовували два набори даних: відомий MNIST – це колекція рукописних цифр, та MAD (Military Activity Dataset) – спеціалізований датасет мелспектрограм аудіозаписів військової активності, включаючи дані з російсько-української війни. Для обох датасетів ми проводили бінарну кластеризацію, тобто ділили дані на два кластери. Якість кластеризації оцінювали за допомогою нормалізованої взаємної інформації (NMI), а якість реконструкції – за середньоквадратичною похибкою (MSE)."

Слайд 10: Експериментальні Результати [MNIST] - Метрики та Реконструкції

- **Текст:** "На датасеті MNIST модель MoA+ показала значно кращі результати кластеризації. NMI для MoA+ склав 0.276, тоді як для стандартної моделі Хінтона – практично нуль. Це означає, що MoA+ набагато краще розділяє зображення на групи. При цьому якість реконструкції (MSE) залишилася приблизно на тому ж рівні. Невелике збільшення MSE є прийнятною платою за суттєве покращення якості кластеризації. Приклади реконструкцій показують, що стандартна модель схильна відносити всі зображення до одного кластера, тоді як MoA+ виконує більш збалансоване розділення."

Слайд 11: Експериментальні Результати [MNIST] - Розподіли Ймовірностей

- **Текст:** "Якщо подивитися на розподіл ймовірностей, які видає роутер, то для стандартної моделі Хінтона відносильну незбалансованість – роутер завжди обирає одного експерта. Це і є проблема "домінування експерта". На відміну від цього, для MoA+ наявні два чіткі піки біля 0 та 1. Це свідчить про те, що роутер впевнено та збалансовано розподіляє зображення між двома експертами. Саме така поведінка роутера і призводить до кращої якості кластеризації."

Слайд 12: Експериментальні Результати [MAD]

- **Текст:** "Далі протестовано моделі на складнішому датасеті MAD, який містить мелспектрограми звуків військових дій. І тут MoA+ знову показала значно вищу якість кластеризації (NMI 0.127) порівняно зі стандартною моделлю (NMI 0.023). Це підкреслює перевагу MoA+ на складних, зашумлених даних"

реального світу. Візуалізації реконструкцій також демонструють, що MoA+ краще розподіляє приклади між кластерами."

Слайд 13: Експериментальні Результати [MAD] - Розподіли

- **Текст:** "Розподіл ймовірностей роутера для датасету MAD також показує переваги MoA+. Хоча піки не такі чіткі, як на MNIST, через більшу складність даних, все ж спостерігається тенденція до бімодального розподілу, що вказує на більш збалансовану роботу експертів. Аналіз розподілу справжніх міток (де 0 – це звуки комунікації, а 1 – звуки перестрілок) показує, що MoA+ намагається групувати схожі звуки разом, наприклад, один кластер переважно захоплює звуки комунікації, а інший – звуки перестрілок. Це свідчить про здатність моделі знаходити значущі структури в даних."

Слайд 14: Висновки

- **Текст:** "Отже, в цій роботі представлено модель MoA+, яка вирішує проблему "домінування експерта" в задачах кластеризації зображень. Ключова інновація – це модифікована функція втрат з використанням "мінімаксних ваг", що забезпечує збалансоване навчання експертів. Експерименти на датасетах MNIST та MAD показали значне покращення якості кластеризації порівняно зі стандартним підходом. Зокрема, успіх на датасеті MAD відкриває перспективи для практичного застосування моделі, наприклад, для аналізу акустичної обстановки в зоні бойових дій. Подальші дослідження можуть включати тестування на ширшому спектрі даних та з більшою кількістю експертів."